

MD JUNAYED MIAH

Data Engineering & DataOps | Maschine Learning

Erlangen, Deutschland | +49 176 73268905 | junayed.miah7667@gmail.com | LinkedIn | GitHub

PROFESSIONELLES PROFIL

Data Science Masterstudent mit praktischer Erfahrung in Data Engineering und Maschine Learning. Ich habe End-to-End Datenpipelines mit Databricks und PySpark entwickelt und Maschine Learning Modelle für reale Probleme gebaut. Ich habe Erfahrung mit ETL-Pipelines, Datenqualität, Cloud-Plattformen und Explainable AI. Ich suche eine Werkstudentenstelle oder eine Junior-Position im Bereich Data Engineering oder Machine Learning.

TECHNISCHE FÄHIGKEITEN

Programmiersprachen & Tools: Python (Pandas, NumPy, Scikit-learn, PyTorch), SQL (PostgreSQL, MySQL), PySpark

Daten Engineering: Databricks, Delta Lake, Auto Loader, Structured Streaming, ETL-Pipelines, Data Modeling

Datenqualität und Prozesse: Datenvalidierung, Qualitätsprüfungen, reproduzierbare Pipelines, grundlegende Überwachung von Datenprozessen

Machine Learning & AI: XGBoost, LSTM, Transformer, SHAP, LIME, Optuna, Hyperopt, MLflow

Visualisierung und BI: Power BI, Tableau, Excel (Power Query)

Sprachen: Englisch (fließend), Deutsch (B1, aktiv am Verbessern)

BERUFSERFAHRUNG

Data Analyst Praktikant: (Monisho Ltd.)

Sep 2019 – Dez 2019

Dhaka, Bangladesch

- Entwickelte ETL-Prozesse, um Verkaufsdaten aus verschiedenen Quellen zu sammeln, zu reinigen und für Berichte vorzubereiten
- Automatisierte manuelle Datensammlung und sparte dadurch 5+ Stunden pro Woche
- Erstellte Power BI Dashboards für Lagerbestände und Verkaufstrends

PROJEKTE

Real-time E-commerce Customer Insights (Medallion Architecture)

Mai 2026 – Jun 2026

Databricks | PySpark | Delta Lake | Auto Loader | Structured Streaming

- Entwurf und Implementierung einer Medallion-Architektur (Bronze, Silver, Gold) in Databricks
- Nutzung von Auto Loader und Structured Streaming für Echtzeit-Datenaufnahme
- Ergebnis: Ein Dashboard mit Kunden-Segmentierung und Verkaufstrends, das alle 5 Minuten aktualisiert wird

Explainable Insurance Cross-Sell Prediction

Jun 2026 – Juli 2026

Python | XGBoost | Optuna | SHAP | LIME | MLflow

- Entwicklung eines XGBoost-Modells zur Vorhersage von Versicherungsverkäufen (16% positive Klasse)
- Hyperparameter-Optimierung mit Optuna
- Erklärung der Modellentscheidungen mit SHAP und LIME (global und lokal)
- Ergebnis: 68.83% F1-Score. Das Modell ist für regulierte Industrien (Versicherung) verständlich und nachvollziehbar

Student Dropout Prediction (LSTM vs Transformer)

Juli 2026 – Aug 2026

PyTorch | LSTM | Transformer | Spark | MLflow

- Verarbeitung von 30.000+ Studenten-Clickstream-Daten (10 Millionen+ Einträge) mit Spark
- Erstellung von Zeitreihen mit 200 Schritten pro Studenten. Vergleich von LSTM und Transformer-Modellen
- Ergebnis: LSTM erreichte 68.83% F1-Score (ähnlich wie Transformer), war aber 3x schneller im Training und war besser für die Produktion

Hyperparameter Tuning Optimization Study

Aug. 2026 – Sep. 2026

Scikit-learn | Optuna | Hyperopt | XGBoost | MLflow

- Vergleich von 4 Optimierungsmethoden (Grid Search, Random Search, Optuna, Hyperopt) - MLflow für Experiment-Tracking verwendet
- Ergebnis: Optuna und Hyperopt erreichten ähnliche F1-Scores wie Grid Search, aber mit 75% weniger Zeit, und somit ideal für Produktionsumgebungen.

AUSBILDUNG

MSc. Data Science Friedrich-Alexander-Universität Erlangen-Nürnberg

seit Okt. 2023

Erlangen, Germany

B.Sc. Computer Science & Engineering North South University

Jan 2015 – Dez 2019

Dhaka, Bangladesch

ZERTIFIKATE & WEITERBILDUNG

- Google Data Analytics (Coursera)
- Become a Data Analyst (AiQuest)

PUBLICATION

- "Development of Online Home Sharing Web Application," IEEE CCWC (2021)